semestr II

Przetwarzanie i analiza dużych zbiorów danych 2020/21

Prowadzący: mgr inż. Rafał Woźniak środa, 11:45

> Piotr Wardęcki 234128234128@edu.p.lodz.pl Paweł Galewicz 234053 234053@edu.p.lodz.pl Bartosz Jurczewski 234067234067@edu.p.lodz.pl

> > Zadanie 4

1. Cel zadania

Celem zadania było napisanie programu, który implementuje reguły asocjacyjne za pomocą algorytmu A-priori. Program na podstawie ostatnio przeglądanych przez użytkowników przedmiotów identyfikuje te, które regularnie występowały wspólnie w ramach pojedynczej sesji.

2. Opis implementacji

Do wykonywania zadania niezbędna była instancji Apache Spark. Aby ograniczyć liczbę zainstalowanych środowisk skorzystaliśmy z odpowiedniego obrazu dla Dockera [1], który zawierał także Jupyter Notebook, Python oraz Miniconda. Dodatkowo aby ułatwić tworzenie środowiska do kolejnych zadań i między naszymi komputerami skorzystaliśmy z narzędzia Docker Compose (nasz plik [2]). Do stworzenia programu bardzo pomocna była funkcja parallelize() która odpowiedzialna była za stworzenie rozproszonego zbioru danych na podstawie listy kolekcji. Pozwalało to na wykorzystanie paradygmatu map-reduce do rozwiązywania większej części zagadnień algorytmu.

3. Wyniki

Tabela 1. 5 reguł asocjacyjnych o największej ufności dla par

Nr	Element	Ufność
1	DAI93865 [FRO40251]	1.0
2	GRO85051 [FRO40251]	0.999176276771005
3	GRO38636 [FRO40251]	0.9906542056074766
4	ELE12951 [FRO40251]	0.9905660377358491
5	DAI88079 [FRO40251]	0.9867256637168141

Tabela 2. 5 reguł asocjacyjnych o największej ufności dla trójek

Nr	Element	Ufność
1	DAI23334 ELE92920 [DAI62779]	1.0
2	DAI31081 GRO85051 [FRO40251]	1.0
3	DAI55911 GRO85051 [FRO40251]	1.0
4	DAI62779 DAI88079 [FRO40251]	1.0
5	DAI75645 GRO85051 [FRO40251]	1.0

4. Wnioski

- Stworzone przez nas reguły asocjacyjne mają najlepsza dokładność dla trojek.
- Najczęściej występującym następnikiem wygenerowanych reguł był [FRO40251].

${\bf Bibliografia}$

- [1] Jupyter Notebook Python, Spark Stack https://hub.docker.com/r/jupyter/pyspark-notebook
- [2] Plik Docker Compose do zadania 2 https://github.com/jurczewski/PiADZD/blob/master/zad2/docker-compose.yml